

Practica 2: Expresiones Regulares

Adriana Pérez Espinosa

1 Introducción

Una *expresión regular* en programación es una forma de representar una secuencia de caracteres que describe un conjunto de cadenas sin enumerar sus elementos y haciendo uso de la sintaxis propia de los diferentes lenguajes de programación.

El uso de *expresiones regulares* constituye un mecanismo flexible y eficiente para el procesamiento de textos que requiere el conocimiento y destreza en un lenguaje de programación relativamente sencillo que sirve para hacer búsquedas en un texto determinado.

Con el uso de algunas herramientas computacionales, como motores de búsquedas, las expresiones regulares pueden utilizarse para añadir, aislar o quitar textos o datos de forma rápida y ágil. Las expresiones regulares se componen de dos tipos de caracteres:

- Los meta-caracteres que son de tipo especial, por ejemplo: *, ?, +.
- Las literales o caracteres normales de texto.

A continuación realizaremos algunos ejemplos para buscar un conjuntos de letras o palabras.

Dado el siguiente archivo llamado: *poema.txt* cuyo contenido es el siguiente:

El mundo al revés

Erase una vez
Un lobito bueno
Al que maltrataban
Todos los corderos.
Y habia tambien
Un principe malo
Una bruja hermosa
Y un pirata honrado.
Todas estas cosas
Habia una vez
Cuando yo sonaba
Un mundo al revés.
Autor: Jose Agustin Goytisolo.
Barcelona 1928 - 1999

Se muestran los siguientes ejemplos del uso de expresiones regulares y meta-caracteres.

Ejemplo 1.- Encontrar todas las letras a,b y c.

```
import re

#Abrir el archivo
file = open('poema.txt',mode='r')

#Leer todas las lineas
archivo = file.read()

print("Vamos a buscar todas las letras comprendidas en el
rango [a-c],es decir, las letras: a, b y c")
#Se buscan todas las coincidencias utilizando la funcion FINDALL
x = re.findall("[a-c]", archivo);
#Se imprime el tamaño de la lista obtenida
print("Se han encontrado:",len(x),"coincidencia");
#Se imprime la lista resultante
print("La lista es:");
print(x)
#Se calculan cuantas coincidencia de cada letra hubo
print("Numero de coincidencias de la letra 'a':", x.count("a"));
print("Numero de coincidencias de la letra 'b':", x.count("b"));
print("Numero de coincidencias de la letra 'c':", x.count("c"));
```

Salida:

Vamos a buscar todas las letras comprendidas en el rango [a-c], es decir, las
letras: a, b y c

Se han encontrado: 41 coincidencia

La lista es:

['a', 'a', 'a', 'b', 'b', 'a', 'a', 'a', 'b', 'a', 'c', 'a', 'b', 'a', 'a', 'b', 'c', 'a', 'a', 'b',
'a', 'a', 'a', 'a', 'a', 'a', 'a', 'c', 'a', 'a', 'b', 'a', 'a', 'a', 'a', 'b', 'a', 'a', 'a', 'c', 'a']

Número de coincidencias de la letra 'a': 29

Número de coincidencias de la letra 'a': 8

Número de coincidencias de la letra 'a': 4

Ejemplo 2.- Encontrar todas las letras mayúsculas.

```
import re

""" Abrir el archivo """
file = open('poema.txt', mode='r')

#Leer todas las lineas
archivo = file.read()
print("Vamos a buscar todas las letras mayusculas")
""" Se buscan todas las coincidencias utilizando
la funcion FINDALL """
x=re.findall("[A-Z]", archivo)
print("Hay", len(x), "letras mayusculas y son: ", x )
```

Salida: Vamos a buscar todas las letras mayúsculas
Hay 17 letras mayúsculas y son:
['E', 'U', 'A', 'T', 'Y', 'U', 'U', 'Y', 'T', 'H', 'C', 'U', 'A', 'J', 'A', 'G', 'B']

Ejemplo 3.- Encontrar todas las palabras que empiezan con 'A'.

```
import re

#Abrir el archivo
file = open('poema.txt', mode='r')
#Leer todas las lineas
archivo = file.read()
print("Vamos a buscar todas las palabras que empiezan con A")
#Se buscan todas las coincidencias utilizando la funcion FINDALL
""" Se buscan todas las palabras que empiezan con A mayusculas """
x=re.findall("A[a-z]+", archivo)
print("Hay", len(x), "palabras y son: ")
print(x)
```

Salida:
Vamos a buscar todas las palabras que empiezan con A (mayúscula)
Hay 3 palabras y son:
['Al', 'Autor', 'Agustin']

Ejemplo 4.- Encontrar todas los artículos Un, un, Uno(s), uno(s), Una(s), una(s).

```
import re

#Abrir el archivo
file = open('poema.txt',mode='r')

#Leer todas las lineas
archivo = file.read()

print("Se buscan todos los articulos un, uno, una, unos, unas ")
print("sin importar su posicion en el texto.")
#Se buscan todas las coincidencias utilizando la funcion FINDITER

count=1;
""" Se buscan todas las letras mayusculas """
""" Explicacion de la expresion :
    [Uu] ---Se busca que inicie con u (mayuscula o minuscula)
        n ---Despues de la u debe ir concatenado una n
    [ao]? ---Despues de la n puede o no ir concatenada una 'a' o
una 'o'
        s? ---Los articulos pueden ser singulares o plurales , por lo
              finalizar con una 's' . """
x=re.finditer("[Uu]n[ao]?s?", archivo)
for i in x:
    print("Articulo:",i.group(), "--En las coordenadas", i.span())
    count=count+1
print("En total se encontraron", count, "articulos")
```

Salida:

Se buscan todos los articulos un, uno, una, unos, unas
sin importar su posición en el texto.
Articulo: un –En las coordenadas (4, 6)
Articulo: una –En las coordenadas (25, 28)
Articulo: Un –En las coordenadas (33, 35)
Articulo: Un –En las coordenadas (104, 106)
Articulo: Una –En las coordenadas (121, 124)
Articulo: un –En las coordenadas (141, 143)
Articulo: una –En las coordenadas (184, 187)
Articulo: Un –En las coordenadas (209, 211)
Articulo: un –En las coordenadas (213, 215)
En total se encontraron 10 articulos

Otra forma de crear la expresión regular del ejemplo anterior y que muestra la misma salida es: $(U|u)n(a|o)?s?$

Ejemplo 5.- Encontrar un secuencias de dígitos en una cadena, en una linea y al final de una cadena.

```
import re

#Abrir el archivo
file = open('poema.txt',mode='r')

#Leer todas las lineas
archivo = file.read()

"""Se buscan todas las coincidencias utilizando """
"""la funcion FINDALL"""

"""Se buscan todas los secuencias de 3 digitos """
print("Se buscan secuencias de 3 digitos")
x=re.findall("(\\d{3})", archivo)
print(x)

"""Se buscan todas los secuencias de 3 digitos """
"""que se encuentren al final de una linea"""
print("Se buscan secuencias de 3 digitos al final de una linea")
x=re.findall('(\\d{3})$', archivo)
print(x)

"""Se buscan todas los secuencias de 3 digitos """
"""que se encuentren al final de una cadena"""

print("Se buscan las cadenas que terminen")
print("con una secuencia de 3 digitos")
x=re.findall('(\\d{3})\\s', archivo)
print(x)
```

Salida:

Se buscan secuencias de 3 digitos

['192','199']

Se buscan secuencias de 3 digitos al final de una linea

['999']

Se buscan las cadenas que terminen con una secuencia de 3 digitos

['928 ','999\\n']

Ejemplo 6.- Encontrar cadenas que empiezan o terminan con una letra.

```
import re

#Abrir el archivo
file = open('poema.txt',mode='r')

#Leer todas las lineas
archivo = file.read()

#Se buscan todas las coincidencias utilizando la funcion FINDALL

print("Se buscan todas las cadenas que terminan con a")
x=re.findall('\w*a\s', archivo)
print(x)
print("Se buscan todas las cadenas que empiezan con p")
x=re.findall('p\w*', archivo)
print(x)
print("Se buscan todas las cadenas que empiezan con p y no terminan en a")
x=re.findall('p[^a]*\s', archivo)
print(x)
```

Salida:

Se buscan todas las cadenas que terminan con a

['una ', 'habia ', 'Una ', 'bruja ', 'hermosa\n', 'pirata ', 'Habia ', 'una ', 'son-
aba\n', 'Barcelona ']

Se buscan todas las cadenas que empiezan con p

['principe','pirata']

Se buscan todas las cadenas que empiezan con p y no terminan en a

['principe']

2 Ejercicios

Tomar el programa base de UAMILang y que al leerlo identifique:

- Todos los identificadores
- Todos los números enteros
- Todos los números reales
- Todos los operadores aritmeticos:+, -, *, /, %, ^
- Todos los operadores lógicos >, <, =
- Otros